

실 LLM 실측 검증 결과 (N=7)

서로 다른 7건의 실제 LLM 실행에서 관측한 준수율·근거·비용·게이트 판정 원자료와 집계

N=7 은 작은 표본이며, 아래 값은 정밀 추정치가 아니라 현재 분포와 한계를 확인한 결과다. 평균은 반드시 범위와 함께 읽어야 한다.

측정 2026-07-28 · 모델 gpt-4o-mini · 원자료 presentation-assets/metrics/sample-n7.json · 샘플 실행 1건의 산출물 전체는 이 폴더의 03~06 파일

1. 측정 조건

모델	gpt-4o-mini (OpenAI) — 실행 로그에 단계별로 기록됨
심판 모델	동일 모델(REVIEWER_MODEL 미설정). 분리 기능은 있으나 이 측정에서는 쓰지 않았다
실행 구조	WORKFLOW_MODE=parallel (배포와 동일)
코드	생성·판정 로직은 동결 커밋과 동일 · KOSENA 점검은 LLM 없이 결정적
표본	7건 = 신규 5개 주제 + 같은 조건의 기존 2건(시각장애인 웨어러블 로컬·배포)
주제당 실행	1회 — 주제 간 차이와 실행 간 편차가 분리되지 않는다(한계 1)
웹 검색	Tavily 정상 동작
총비용	약 \$0.15 (7건 합계 \$0.1512)

주제는 데이터 가용성이 서로 다르게 골랐다 — 결과가 주제에 따라 얼마나 흔들리는지 보는 것이 목적이다: B2B SaaS · 소비자앱 · 커머스 · 헬스케어 규제 · 산업 니치 · 접근성 하드웨어(×2). 따라서 주제 다양성은 실질 6종이다.

2. 주제별 원자료 — KOSENA 준수 · 근거 · 사실검증

주제	run_status	KOSENA	부분	미충족	미충족·부분 항목	근거	조회 시점	발행 일	주장 확인/전체	확인율
소상공인 재고·발주 예측 서비스	success	26/28	2	0	competitors_3_2_1 · doc_length	18	18	4	1/5	0.20
반려동물 이상행동 조기 감지 앱	success	26/28	2	0	competitors_3_2_1 · doc_length	18	18	3	1/5	0.20
중고 의류 리커머스 큐레이션 플랫폼	success	26/28	2	0	competitors_3_2_1 · doc_length	9	9	4	3/5	0.60
고령자 복약 관리·보호자 알림 서비스	success	27/28	1	0	doc_length	19	19	2	1/5	0.20
제조 현장 안전 위험 감지 시스템	success	26/28	2	0	competitors_3_2_1 · doc_length	17	17	4	3/5	0.60
시각 장애인 웨어러블 (로컬)	success	27/28	1	0	doc_length	17	17	4	3/5	0.60
시각 장애인 웨어러블 (배포 00009)	success	27/28	1	0	doc_length	19	19	4	1/1	1.00

노란 행 = 이 폴더의 샘플 결과 세트(03~06)와 같은 실행. · KOSENA 열은 '충족' 개수이며 부분·미충족을 따로 적었다. · '조회 시점' = `retrieved_at` 이 기록된 근거 수, '발행일' = `published_date` 가 있는 근거 수(검색이 줄 때만 채운다).

3. 주제별 원자료 — 비용 · 시간 · 채택 판정

주제	LLM 호출	토큰	비용	소요(초)	채택본	심판 점수	release _ready	KOSENA Agent
소상공인 재고·발주 예측 서비스	19	103,094	\$0.0216	178.4	revised	67	false	4/4
반려동물 이상행동 조기 감지 앱	19	109,048	\$0.0223	163.6	revised	61	false	4/4
중고 의류 리커머스 큐레이션 플랫폼	17	69,292	\$0.0162	148.1	draft	65	false	4/4
고령자 복약 관리·보호자 알림 서비스	19	119,647	\$0.0239	171.5	revised	75	false	4/4
제조 현장 안전 위험 감지 시스템	18	103,189	\$0.0213	158.7	revised	70	false	4/4
시각 장애인 웨어러블 (로컬)	18	108,345	\$0.0223	171.1	draft	64	false	4/4
시각 장애인 웨어러블 (배포 00009)	19	116,718	\$0.0236	167.5	revised	69	false	4/4

'KOSENA Agent' = `kosena_industry` · `kosena_model` · `kosena_research` · `kosena_roadmap` 4종이 산출물을 만든 비율. · 비용은 단가표 기반 추정치다(실제 청구액이 아니다).

4. 집계 (N=7)

지표	평균	증양값	범위	표준편차
KOSENA 충족(/28)	26.4	26	26~27	0.53
근거 건수	16.7	18	9~19	3.5
LLM 호출	18.4	19	17~19	0.8
토큰	104,190	108,345	69,292~119,647	16,617
비용(USD)	\$0.0216	\$0.0223	\$0.0162~\$0.0239	0.0026
소요(초)	166	168	148~178	9.9
근거 확인율	0.49	0.60	0.20~1.00	0.30
심판 점수	67.3	67	61~75	4.6

5. 성공 · 폴백 · 실패 노드

항목	결과	의미
run_status	7/7 success	7건 모두 처음부터 끝까지 완주했다
fallback_nodes	0건	LLM 실패를 대체 출력으로 흡수한 노드가 없었다
failed_nodes	0건	실패로 표기된 노드가 없었다
fallback_calls	0회	LLM 호출 수준의 폴백도 없었다
KOSENA Agent 4종 완주	7/7 (4/4)	M1·M2·M3 산출물을 만드는 4개 Agent 전부 결과를 냈다

완주 ≠ 결과 보존. 이 표본은 전부 스크립트 경로로 측정했다. 별도로 **UI 실행 경로(/run/stream)에서 State 병합이 KOSENA 결과를 덮어쓰는 결함**이 있었고(28키 → 10키, 11/28), 원인은 코드이며 **결정적**이었다. 수정 후 실 LLM 로 같은 경로를 관통 검증했다(28키 · 27/28 · 미충족 0). 회귀 테스트 tests/test_stream_reducer_parity.py. 이 표본의 수치는 결함 경로를 타지 않아 그대로 유효하다.

6. KOSENA 준수 — 26~27/28 의 내부

7건 중 27/28 이 3건, 26/28 이 4건이다. 그래서 단일 대표값을 27/28 로 말하면 표본이 지지하지 않는다. 정확한 표현은 26~27/28(평균 26.4) 다.

반복 미충족 항목	빈도	성격
doc_length	7/7	구조적 — 요건 A4 30~50쪽, 실측 약 11~13쪽. 분량을 위한 분량을 넣지 않기로 판단한 결과다
competitors_3_2_1	4/7	LLM 출력 편차 — 직접 경쟁사 3개를 요구하는데 2개만 생성하는 경우. 26 과 27 을 가르는 유일한 변수이며, 모자란 개수를 지어내 채우지 않기 때문에 부분 충족으로 보고된다

모듈별로는 이 샘플 실행에서 M1 8/8 · M2 10/10 · M3 6/6 · 공통 3/4(부분 1건 = doc_length , 약 13.6쪽)이었다.

7. 품질 게이트 — 0/7 통과

`release_ready=true` 가 한 건도 없다. 게이트가 작동한다는 뜻이고, 동시에 현재 산출물이 자동 출판 기준에는 못 미친다는 뜻이다.

차단 사유	빈도	임계값	실측
<code>score</code>	7/7	≥ 80 점	61~75 (평균 67.3)
<code>major_issues</code>	7/7	≤ 1 건	초과
<code>evidence</code>	6/7	충족률 ≥ 0.8	0.20~1.00

임계값은 `calibrated: false` — 사람이 쓴 기획서로 기준선을 보정하기 전의 잠정값이다. 따라서 "80점을 넘지 못했다"를 곧 "품질이 낮다"로 읽으면 안 된다.

8. 초안 복원 2/7 — AI 응답을 그대로 쓰지 않았다는 증거

재작성본이 초안보다 낮게 평가되면 초안으로 되돌린다(`best_version`). 7건 중 **2건(29%)** 에서 실제로 되돌렸다 — 중고 의류 리커머스 큐레이션 플랫폼 · 시각 장애인 웨어러블 (로컬).

9. 근거 확인율의 흔들림 (0.20~1.00)

표준편차 0.30 이다. 검증 Agent 가 주장을 **매번 새로 추출**하기 때문이고, 이 값이 게이트의 `evidence` 판정에 쓰이므로 **게이트 결과에 운이 섞인다**. 미해결 과제로 기록했다.

부수 관찰: 추출된 주장 수가 7건 중 6건에서 정확히 5건, 1건이 1건이었다. 분모가 작아 한 주장 차이로 확인율이 0.2 씩 움직인다(1/5). 비율로만 해석하면 과대·과소가 쉽다. · 근거 117건 전부 `retrieved_at` 이 있고, `published_date` 는 25건(21%)이다 — 검색이 잘 때만 채우고 없으면 '미상'으로 두므로 낮은 것이 정상이다.

10. 이 표본의 한계 (반드시 함께 말할 것)

- 주제당 1회 실행이다.** 주제 간 차이와 실행 간 편차가 분리되지 않는다. `competitors_3_2_1` 이 4/7 인 것이 "그 주제는 경쟁사가 2개뿐"인지 "같은 주제도 실행마다 흔들리는지" 구분할 수 없다. 분리하려면 같은 주제를 반복 실행해야 한다.
- N=7 은 작다.** 평균을 정밀 추정치로 제시하지 않고 범위와 함께 말한다.
- 모델 1종 · 언어 1종 · 심판 1종**이다. 모델을 바꾸면 값이 달라질 수 있다.
- 시각장애인 웨어러블 2건은 같은 주제이므로 **주제 다양성은 실질 6종**이다.
- 심판이 LLM(`gpt-4o-mini`)**이다. 점수는 절대 척도가 아니며, 이 측정에서는 생성 모델과 같은 모델이 채점했다.
- 비용·토큰은 **추정 집계**이고, 소요 시간은 외부 API 응답 속도에 좌우된다.